

正交化梯度方法的数值分析视角： 从 Newton-Schulz 极分解到 Muon 优化器及其统一框架

赵泽霖 (2023010848) 史云天 (2023010836)

课程：数值分析与算法

2026 年 6 月 6 日

摘要

近年来 Muon 优化器把矩阵正交化（极分解的多项式近似）引入深度学习训练，被认为是 Adam 之后第一个“非对角”型现代优化器；同期理论上 Kovalev (2025) 将它解释为谱范数 trust-region 线性子问题的最速下降。我们把 Muon 重新放回矩阵迭代/矩阵函数这一经典数值分析背景：核心数值步骤 Newton-Schulz 迭代 $X_{k+1} = \frac{1}{2}X_k(3I - X_k^\top X_k)$ 是 Higham 教材里的极分解迭代，具有局部二次收敛性和明确的收敛盆 $\sigma_0 \in (0, \sqrt{3})$ 。围绕这个核心，我们做四件事：

- 完整的数值分析视角推导**：给出 GD 在强凸二次上的线性收敛、Heavy-ball 谱半径最优性、Heavy-ball 作为 Chebyshev 半迭代定常极限的关系、Newton-Schulz 二次收敛（含 $E_{k+1} = -\frac{1}{4}E_k^2(3I - E_k)$ 完整推导）、以及极分解作为谱范数 trust-region 线性子问题最速下降方向的最优性证明。
- 三条前沿链条**：把 Muon 的 trust-region 解释、Adam/AdamW 收敛与 Bock-Weiß 极限环、Su-Boyd-Candès AVD-ODE 和高分辨率 ODE 全部纳入同一个 $x_{k+1} = x_k - P_k g_k$ 模板下讨论。
- 20 组数值实验**：覆盖病态二次 ($\kappa \in \{10, 100, 10000\}$)、谱范数 trust-region 损失、Heavy-ball/Chebyshev 定常极限关系、Adam 2-极限环、NAG-ODE 与离散迭代的相图对照、Newton-Schulz 收敛盆边界 $\sqrt{3}$ 的直接观测。
- 代码与可复现**：14 项 pytest + 一键复现脚本 + 33 张图自动生成；图表与正文 claim 数值上严格对齐。

关键发现：Muon 与 GD 优化不同的每步几何（谱范数 trust-region vs Frobenius 梯度），不宜在同一损失上简单比优劣；在 Frobenius 矩阵二次上 Muon 发散而 GD 收敛，正是 trust-region 最优性定理所预言的几何错配。Muon 在谱范数恢复目标上跨种子稳定降至 0.03 平台，验证的是 trust-region 方向匹配，而非全局精度超越 GD。Polyak 最优 Heavy-ball 可看作 Chebyshev 半迭代的定常极限；实验 25 末段 gap 差距 1.7×10^{-13} 。Newton-Schulz 收敛盆 $(0, \sqrt{3})$ 由实验 30 在 100 个初值上直接证实。

关键词：Newton-Schulz 迭代；极分解；Muon 优化器；谱范数 trust-region；Chebyshev 半迭代；Heavy-ball；Nesterov 加速；动态预条件；ODE 离散化。

1 引言

1.1 这门课讲了什么

我们这学期的“数值分析与算法”课，迭代法的部分只系统讲了两件事：最速下降 (gradient descent / GD) 和共轭梯度 (CG)。然而工业界的深度学习训练里，最常见的优化器名字根本不在课本上——Adam、AdamW、Sophia，以及 2024 年 Jordan 等人提出、被 Moonshot 等公司用在 LLM 预训练里的 **Muon**。它们看起来像是“调参玄学”，但很少有人从**数值迭代**的角度看它们到底在做什么。

我们想做的事情很简单：把这些“看起来像玄学”的优化器，全部重写成统一的数值迭代模板

$$x_{k+1} = x_k - P_k g_k, \quad g_k = \nabla f(x_k) \quad (1.1)$$

然后用我们课内学到的工具——谱半径、条件数、Chebyshev 多项式、矩阵函数迭代——去分析它们的收敛、稳定性和几何意义。在所有这些优化器里，**Muon** 是最有意思的一个：它的核心步骤 Newton-Schulz 迭代是 Higham 教材里的标准矩阵函数迭代，二次收敛，有解析的收敛盆 $(0, \sqrt{3})$ 。这给了我们一个用“纯数值分析”贯穿整篇论文的主线。

1.2 我们为什么选 Muon 做核心

我们曾经考察了多个候选方向，最终选择了以 Muon 作为核心，原因是：

1. **它是真的“现代”前沿**——Muon 2024 年 10 月才上 GitHub，2025 年才有理论文章 [7, 8]。
2. **它最数值分析**——Adam 是机器学习圈的工程产物，理论分析里大多是 regret bound；Muon 不一样，它的核心子程序就是 Higham 教材第 8 章里讲的极分解 Newton-Schulz 迭代 [4, 11]，这是 1933 年 G. Schulz 提出的纯数值算法。
3. **它在我们能写的篇幅里有完整的理论闭环**：从极分解的存在唯一性，到 Newton-Schulz 二次收敛和 $\sqrt{3}$ 收敛盆，到 Kovalev 的谱范数 trust-region 线性化解释，每一步都能严格证明，不需要随机假设。

下面这张表是我们的“路线图”。横向是机制 (P_k 的形态)，纵向是它在课内 / 前沿的对应：

表 1: 统一模板 $x_{k+1} = x_k - P_k g_k$ 下的优化器对照

P_k 形态	经典对应	现代名字	我们要证 / 验证的
ηI (标量步长)	Richardson / 显式 Euler	GD	强凸线性收敛 (定理 3.1)
$\eta I + \text{二阶状态}$	Chebyshev 半迭代	Heavy-ball, Nesterov	HB $\equiv$ Chebyshev (定理 3.3) + AVD-ODE 离散
$\eta \text{diag}(\hat{v}_k)^{-1/2}$	动态 Jacobi 预条件	Adam, AdamW	动态预条件 + Bock-Weiß 2-极限环
$\eta \text{diag}(h_k)^{-1}$	对角拟 Newton	Sophia	κ_{eff} 比 Adam 小
矩阵正交化 $G \rightarrow UV^\top$	Newton-Schulz 矩阵迭代	Muon	二次收敛 + 谱范数 trust-region 最优 (定理 4.1, 4.2)

本文的安排是：第 2 节给数值迭代的预备知识；第 3 节是 GD/HB/Adam 三大基线机制；第 4 节是核心——Newton-Schulz 和 Muon；第 5 节是 ODE 视角；第 6 节是数值实验；第 7 节结论。完整证明放在附录 B；实验数值表在附录 A。

2 预备：迭代法的收敛理论

2.1 谱半径、Lipschitz 与强凸

设 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 二阶可微。若存在常数 $0 < \mu \leq L$ 使得

$$\mu I \preceq \nabla^2 f(x) \preceq LI \quad \forall x,$$

则称 f μ -强凸且 梯度 L -Lipschitz 连续。条件数定义为 $\kappa = L/\mu$ 。

本文的核心模型问题是强凸二次

$$f(x) = \frac{1}{2}x^\top Ax - b^\top x, \quad A = A^\top \succ 0,$$

此时 $\mu = \lambda_{\min}(A)$ 、 $L = \lambda_{\max}(A)$ 、唯一极小点 $x^* = A^{-1}b$ ，且 $\nabla f(x) = Ax - b$ 。优化等价于解线性方程组 $Ax = b$ ，因此整篇论文的“优化”和“求解”是同一回事——这是把现代优化器与课内迭代法直接挂钩的根本理由。

2.2 Krylov 子空间与 Chebyshev 多项式 (CG 的本质)

课内讲 CG 时用的是“共轭性 + 子空间最优”的几何论证。本节用 Chebyshev 多项式的视角重述，因为 Heavy-ball 优化器的最优性证明用得到同一套工具 [10, 14]。

设 x_0 是 CG 的初值， $r_0 = b - Ax_0$ 。CG 的第 k 步迭代 x_k 在仿射 Krylov 子空间

$$x_0 + K_k(A, r_0), \quad K_k(A, r_0) = \text{span}\{r_0, Ar_0, \dots, A^{k-1}r_0\}$$

中最小化 A -范数误差 $\|x - x^*\|_A := \sqrt{(x - x^*)^\top A(x - x^*)}$ 。等价地，误差 $e_k = x_k - x^*$ 写成

$$e_k = p_k(A)e_0, \quad p_k \in \mathcal{P}_k^0 := \{p \in \mathcal{P}_k : p(0) = 1\}.$$

CG 选的就是使 $\|p_k(A)e_0\|_A$ 最小的 p_k ，因此

$$\|e_k\|_A \leq \min_{p \in \mathcal{P}_k^0} \max_{\lambda \in [\mu, L]} |p(\lambda)| \cdot \|e_0\|_A.$$

右边是经典 Chebyshev 最佳逼近问题。其解为缩放的 Chebyshev 多项式：

$$p_k^*(\lambda) = \frac{T_k\left(\frac{L+\mu-2\lambda}{L-\mu}\right)}{T_k\left(\frac{L+\mu}{L-\mu}\right)},$$

其中 $T_k(t)$ 是第一类 Chebyshev 多项式。带入得到课内的经典上界：

$$\|e_k\|_A \leq 2 \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \|e_0\|_A. \quad (2.1)$$

这一步是后面所有“加速类”方法（Heavy-ball、Nesterov、Chebyshev 半迭代）的共同上界。

2.3 极分解：矩阵函数视角

定理 2.1 (Higham 2008, Theorem 8.1). 对任意 $G \in \mathbb{R}^{m \times n}$ (设 $m \geq n$, G 列满秩), 存在**唯一**分解

$$G = UH, \quad U \in \mathbb{R}^{m \times n}, \quad U^\top U = I_n, \quad H \in \mathbb{R}^{n \times n}, \quad H = H^\top \succeq 0.$$

U 称为 G 的**正交因子**, H 称为 *Hermitian* 因子。若 $G = \hat{U}\Sigma V^\top$ 是 *SVD*, 则 $U = \hat{U}V^\top, H = V\Sigma V^\top$ 。

我们在第 4 节会证明 Muon 的更新方向就是 $-U$, 并解释这就是谱范数 trust-region 线性子问题的最速下降方向 [7].

3 三大基线机制：GD、Heavy-ball、Adam

3.1 GD 与 Richardson 迭代

GD 的更新 $x_{k+1} = x_k - \eta(Ax_k - b)$ 在数值分析的语言里就是求解 $Ax = b$ 的 **Richardson 迭代** [10]。预条件 $P_k = \eta I$ 是统一模板 (1.1) 的最简形式。

算法 1 梯度下降 (Richardson 迭代)

输入: 矩阵 $A \succ 0$, 向量 b , 步长 $\eta \in (0, 2/L)$, 初值 x_0

输出: 近似解 x_k

```

1: for  $k = 0, 1, 2, \dots$  do
2:    $g_k \leftarrow Ax_k - b$ 
3:    $x_{k+1} \leftarrow x_k - \eta g_k$ 
4: end for

```

定理 3.1 (GD 在强凸二次上的线性收敛). 设 $A \succ 0$, 谱在 $[\mu, L]$ 。取 $\eta \in (0, 2/L)$, 则 GD 满足

$$\|x_{k+1} - x^*\|_2 \leq \rho(\eta) \|x_k - x^*\|_2, \quad \rho(\eta) = \max_i |1 - \eta \lambda_i(A)|.$$

最优步长 $\eta^* = 2/(\mu + L)$ 处 $\rho^* = (\kappa - 1)/(\kappa + 1)$ 。完整证明见附录 B。

实验对照: $\kappa = 100$ 时 $\rho^* \approx 0.9802$; 实验 5 在 200 个步长上验证 $\rho(\eta)$ 的 V 形; 实验 6 用对数线性拟合得到 $\kappa = 1000$ 时 $\rho_{\text{emp}} = 0.9959$, 与理论 0.998 相对误差 0.2%。

3.2 Heavy-ball、Nesterov 与 Chebyshev 半迭代

Polyak Heavy-ball 更新

$$v_{k+1} = \beta v_k + g_k, \quad x_{k+1} = x_k - \eta v_{k+1}.$$

在 A 的特征基下, 每个模态 $\lambda \in [\mu, L]$ 给出 2×2 系统

$$\begin{bmatrix} x_{k+1} \\ v_{k+1} \end{bmatrix} = T(\lambda) \begin{bmatrix} x_k \\ v_k \end{bmatrix}, \quad T(\lambda) = \begin{bmatrix} 1 - \eta\lambda + \beta & -\beta \\ 1 & 0 \end{bmatrix}.$$

定理 3.2 (Polyak 最优 Heavy-ball 谱半径). 取

$$\eta^* = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta^* = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2,$$

算法 2 Polyak Heavy-ball 方法**输入:** $A \succ 0$, b , 步长 η , 动量 β , 初值 x_0, x_{-1} **输出:** 近似解 x_k

```

1:  $v_0 \leftarrow 0$ 
2: for  $k = 0, 1, 2, \dots$  do
3:    $g_k \leftarrow Ax_k - b$ 
4:    $v_{k+1} \leftarrow \beta v_k + g_k$ 
5:    $x_{k+1} \leftarrow x_k - \eta v_{k+1}$ 
6: end for

```

则所有模态 $\lambda \in [\mu, L]$ 的谱半径都等于 $\rho_{\text{HB}}^* = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ [9]。完整证明见附录 B。

与 GD 对比: $\kappa = 100$ 时 $\rho_{\text{HB}}^* \approx 0.818$, 比 GD 的 0.980 加速因子约 $9.9\times$ 。实验 2 在 $\kappa \in [10, 1000]$ 上数值验证。

Nesterov 加速:

$$y_k = x_k + \beta(x_k - x_{k-1}), \quad x_{k+1} = y_k - \eta \nabla f(y_k),$$

取 $\eta = 1/L$, $\beta = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ 。实验 11 显示: $\kappa = 100$ 时 Nesterov 70 步达 10^{-6} 、Polyak HB 68 步、GD 439 步。

定理 3.3 (Heavy-ball 是 Chebyshev 半迭代的定常极限)。对二次问题 $f(x) = \frac{1}{2}x^\top Ax - b^\top x$, Chebyshev 半迭代 (Hageman–Young 形式) 使用时变系数 ω_k ; 当 ω_k 收敛到不动点 ω_∞ 后, 其递推退化为 Polyak 最优 Heavy-ball 形式。即 Polyak HB 可视为 Chebyshev 半迭代的定常极限。完整证明见附录 B。

数值验证 (实验 25): 在 $\kappa = 100$, $d = 20$ 上跑 200 步, 两者末段 $f - f^*$ 差距为 1.7×10^{-13} 。这个定理是把课内 Chebyshev/CG 与现代动量法直接挂钩的桥梁。

3.3 Adam = 动态 Jacobi 预条件 + 极限环现象

Adam 更新规则 [6]:

$$\begin{aligned}
m_k &= \beta_1 m_{k-1} + (1 - \beta_1) g_k, \\
v_k &= \beta_2 v_{k-1} + (1 - \beta_2) g_k \odot g_k, \\
\hat{m}_k &= m_k / (1 - \beta_1^k), \quad \hat{v}_k = v_k / (1 - \beta_2^k), \\
x_{k+1} &= x_k - \eta \hat{m}_k \odot (\sqrt{\hat{v}_k} + \varepsilon).
\end{aligned}$$

代入统一模板: $P_k = \eta \text{diag}(\sqrt{\hat{v}_k} + \varepsilon)^{-1}$, 这是一个**动态对角预条件**。

命题 3.4 (Adam 与 Jacobi 预条件)。设 $\beta_1 = 0$ 、 v_k 进入稳态时近似 $v_k \approx \mathbb{E}[g \odot g]$ 。对二次目标, 当 A 对角且 $\Sigma_x \propto I$ 时 $P_k \approx \eta \text{diag}(A)^{-1}$, 恰为 Jacobi 预条件器。证明见附录 B。

Bock–Weiß 2-极限环现象 [2]: Adam 即使在最简单的凸函数 $f(x) = \frac{1}{2}ax^2$ 上也可以不收敛, 而是收敛到一个 2-极限环。

示例 3.5 (Adam 2-极限环的数值复现)。实验 26 取 $a = 1$ 、 $\eta = 0.05$ 、 $\beta_1 = 0$ 、 $\beta_2 = 0.99$ 、 $\varepsilon = 10^{-12}$, 在 $x_0 = 1$ 启动 2000 步, 极限环检测算法识别出

$$x^+ \approx 0.0250, \quad x^- \approx -0.0251, \quad |x^+ - x^-| \approx 0.05.$$

这不是数值噪声——尾段 200 步内 $\max(x) - \min(x) = 0.056$ 稳定。

4 核心：Newton–Schulz 迭代与 Muon

4.1 Newton–Schulz 迭代

设 $G \in \mathbb{R}^{m \times n}$ ($m \geq n$, 列满秩), 考虑迭代

$$X_0 = \frac{G}{\|G\|_2}, \quad X_{k+1} = \frac{1}{2} X_k (3I - X_k^\top X_k). \quad (4.1)$$

这就是 Schulz (1933) 提出的 Newton 型矩阵函数迭代 [4, 11]。在标量情形下退化为 $x_{k+1} = x_k(3 - x_k^2)/2$ 。

算法 3 Newton–Schulz 极分解迭代

输入: 矩阵 $G \in \mathbb{R}^{m \times n}$ (列满秩)

输出: 正交因子近似 $X_k \approx U$

- 1: $X_0 \leftarrow G/\|G\|_2$
 - 2: **for** $k = 0, 1, 2, \dots$ **do**
 - 3: $X_{k+1} \leftarrow \frac{1}{2} X_k (3I - X_k^\top X_k)$
 - 4: **end for**
-

定理 4.1 (局部二次收敛). 若 X_0 满足 $\sigma_{\min}(X_0) > 0$ 且 $\sigma_{\max}(X_0) < \sqrt{3}$, 则 (4.1) 二次收敛到 G 的极分解正交因子 U 。令 $E_k = X_k^\top X_k - I$, 则

$$E_{k+1} = -\frac{1}{4} E_k^2 (3I - E_k), \quad (4.2)$$

故 $\|E_{k+1}\|_F \leq \frac{1}{4} \|E_k\|_F^2 (3 + \|E_k\|_F)$, 即 $\|E_k\|_F$ 二次衰减。

证明. 设 $G_k = X_k^\top X_k$ 。由 (4.1), $G_{k+1} = \frac{1}{4} (3I - G_k) G_k (3I - G_k)$ 。代入 $G_k = I + E_k$, 展开化简得 $E_{k+1} = -\frac{1}{4} E_k^2 (3I - E_k)$ 。取 Frobenius 范数, 当 $\|E_k\|_F < 1$ 时 $\|E_{k+1}\|_F < \|E_k\|_F^2$, 即二次收敛。□

收敛盆 $(0, \sqrt{3})$ 的标量证明: 设 σ 是 X_k 的某个奇异值, 则迭代映射为 $\varphi(\sigma) = \sigma(3 - \sigma^2)/2$ 。函数在 $\sigma \in (0, \sqrt{3})$ 内保持在吸引盆中; 当 $\sigma > \sqrt{3}$ 时通常进入发散轨道。

实验 30: 在 100 个初值 $\sigma_0 \in [0.05, 2.5]$ 上跑 NS, 落在 $[0.05, \sqrt{3})$ 内的初值全部收敛; 落在 $(\sqrt{3}, 2.5]$ 的 11 个初值全部发散, 与定理预言位级一致 (图 1)。




图 1: Newton–Schulz 收敛盆: σ_0 与 40 步后 $|\sigma^2 - 1|$

4.2 五次多项式 Higham 加速

实验 27 用 Higham (2008, eq. 8.20) 五次多项式

$$X_{k+1} = \frac{1}{8}(15X_k - 10X_k(X_k^\top X_k) + 3X_k(X_k^\top X_k)^2),$$

可验证 $\phi(1) = 1$ 、 $\phi'(1) = \phi''(1) = 0$ ，5 步达机器精度，标准三阶 NS 要 11–15 步 [1, 4]。

4.3 Muon 优化器：谱范数 trust-region

Muon 的更新规则 [5]：

算法 4 Muon 优化器 (矩阵参数)

输入： 矩阵参数 W ，损失 $f(W)$ ，步长 η ，动量参数

输出： 更新后的 W_{k+1}

- 1: 计算带 Nesterov 动量的梯度矩阵 M_k
 - 2: $\widetilde{M}_k \leftarrow \text{NEWTONSCHULZ}(M_k)$
 - 3: $W_{k+1} \leftarrow W_k - \eta \widetilde{M}_k$
-

▷ 算法 3

定理 4.2 (极分解的 trust-region 最优性). 对任意 $G \in \mathbb{R}^{m \times n}$ ($\text{rank}(G) = r > 0$),

$$-tUV^\top \in \arg \min_{\substack{\Delta \in \mathbb{R}^{m \times n} \\ \|\Delta\|_2 \leq t}} \langle G, \Delta \rangle_F,$$

其中 $G = U\Sigma V^\top$ 是紧 SVD [7]。

证明. 设 $\Delta = \widetilde{U}\widetilde{\Sigma}\widetilde{V}^\top$, $\|\Delta\|_2 = \widetilde{\sigma}_{\max} \leq t$. 由 von Neumann 迹不等式,

$$|\text{tr}(\Delta^\top G)| \leq \sum_{i=1}^r \sigma_i(\Delta) \sigma_i(G) \leq t \sum_i \sigma_i(G) = t \|G\|_*.$$

等号由 $\Delta = -tUV^\top$ 取到。 □

含义： Muon 在谱范数 trust-region 上做线性逼近最速下降。这就是为什么 Muon 与 Frobenius GD 在 Frobenius 损失上不必一致。

4.4 Muon 在匹配谱范数几何的目标上下降

为展示 Muon 的优势，实验 12 和 28 设计了**谱范数恢复目标**

$$\min_{W \in \mathbb{R}^{m \times n}} f(W) = \frac{1}{2} \|W - W^*\|_\sigma^2,$$

其中 $\|\cdot\|_\sigma$ 是谱范数。实验 12 左图 (80 步、 $W_0 = 0$): Muon-NS 从 1.077 降到 **0.037**; GD 终值 2.4×10^{-32} 、Adam 终值 1.1×10^{-4} 。注意 $W_0 = 0$ 时 $\nabla f(0) = -W^*$, GD 沿 W^* 直线下降, 故左图中 GD 曲线往往最低——这是初值巧合, 详见 §6 对图 7 的读图说明。实验 28 在 5 个种子上 Muon 最终损失 0.028~0.037 高度一致。

与 Frobenius 矩阵二次的对照 (exp12 右图): 在 $\min_W \frac{1}{2} \|AW - B\|_F^2$ 上 Frobenius GD 降到 $f - f^* = 51$, Muon 反而高达 63266——这才是 Muon 与 GD 几何错配的典型表现, 也是定理 4.2 的直接含义。




图 2: Muon 在谱范数损失 vs Frobenius 矩阵二次上的表现 (左: $W_0 = 0$ 时 GD 因 $\nabla f(0) = -W^*$ 往往最低)

4.5 如何理解 Muon 与 GD 的对比

读者容易得出“Muon 各种角度不如 GD”的印象，这源于用错了比较标尺：Muon 不是 Frobenius 意义下的 GD 替代品，而是换了一套预条件几何 P_k （矩阵正交化 + 谱范数 trust-region）。二者在统一模板 $x_{k+1} = x_k - P_k g_k$ 下可比的是机制与理论，不宜在同一损失、同一初值下简单比“谁更小、谁更快”。

表 2: Muon 与 GD 在不同实验中的角色对照

实验场景	GD 的表现	Muon 应如何解读
向量强凸二次 (exp1)	基准方法，收敛慢但可靠	不适用；Muon 面向矩阵参数
Frobenius 矩阵二次 (exp12 右)	正常下降至 $f - f^* = 51$	发散至 63266：说明 Muon 不能替代 Frobenius GD
谱范数恢复 (exp12 左 / exp28)	$W_0=0$ 时常因 $\nabla f(0)=-W^*$ 直达 10^{-32}	稳定降至 0.03 平台：验证 trust-region 方向几何匹配，非全局精度

Muon 的价值不在“全面打败 GD”，而在：

1. **理论闭环**：核心子程序 Newton-Schulz 是课内矩阵函数迭代；定理 4.2 给出每步在谱范数 trust-region 下的最优方向（von Neumann 迹不等式取等）。
2. **几何分工**：GD 优化 Frobenius 线性子问题；Muon 优化谱范数 trust-region 线性子问题——目标不同，胜负不可直接横比。
3. **工程动机** [5, 7]：LLM 训练中矩阵型隐层权重需要在谱范数意义下控制更新幅度；Muon 用 NS 高效近似极分解正交因子，提供与 Adam 不同的**非对角**预条件 P_k 。
4. **本报告实验目的**：验证上述几何解释（NS 收敛盆、trust-region 方向、Frobenius 错配），而非在简化二次模型上宣称 Muon 优于 GD。

5 ODE 视角：连续极限与高分辨率

5.1 梯度流与 GD = 显式 Euler

梯度流 ODE $\dot{x}(t) = -\nabla f(x(t))$ 的前向 Euler 离散即 GD: $x_{k+1} = x_k - \eta \nabla f(x_k)$ [3]。这就把 GD 放进了数值 ODE 的语言里。

5.2 AVD-ODE (Su–Boyd–Candès 2016)

把 Nesterov 加速写成

$$y_k = x_k + \frac{k-1}{k+2}(x_k - x_{k-1}), \quad x_{k+1} = y_k - \eta \nabla f(y_k),$$

令 $X(t = k\sqrt{\eta}) \approx x_k$ 、 $\eta \rightarrow 0$, Su 等证明 X 满足 [13]

$$\ddot{X}(t) + \frac{3}{t}\dot{X}(t) + \nabla f(X(t)) = 0. \quad (5.1)$$

(5.1) 是带衰减阻尼 $3/t$ 的二阶 ODE, 在 f 凸时给出 $f(X(t)) - f^* = O(1/t^2)$ 。

5.3 高分辨率 ODE (Shi et al. 2021)

Shi 等提出高分辨率 ODE [12]

$$\ddot{X} + \gamma \dot{X} + (1 + \sqrt{\eta}\gamma)\nabla f(X) + \sqrt{\eta}\nabla^2 f(X)\dot{X} = 0,$$

最后一项 $\sqrt{\eta}\nabla^2 f\dot{X}$ 是 $O(\sqrt{\eta})$ 修正, 区分 NAG 和 Heavy-ball: 经典 (5.1) 看不出二者差异, 高分辨率 ODE 表明 NAG 多了曲率信息项。

5.4 数值对照 (实验 29)

实验 29 在 2 维 $\kappa = 50$ 二次上: 用 RK4 积分 (5.1); 跑离散 NAG 和 Polyak HB。在连续时间 $t = \sqrt{\eta}k$ 下, 离散 NAG 与 AVD-ODE 呈现相近的下降相图 (图 3)。




图 3: NAG-ODE 解 vs 离散 NAG/HB 的相图对照

6 数值实验

6.1 实验列表（精选）

表 3: 主要数值实验与关键结果

编号	主题	关键数值
1	$\kappa \in \{10, 100, 1000\}$ GD/HB/Adam	$\kappa=100$: HB 68 步、Adam 288 步、GD 439 步
2	Polyak HB 谱半径理论	$\rho_{HB}^*=0.818, \rho_{GD}=0.980$
4	Adam κ_{eff} 演化	fast-adapt 配置 κ_{eff} 降到 16.7
8	Jacobi vs Adam	对角 A: Jacobi 1 步; 稠密 A: $\kappa_{\text{eff}}=312$
11	Nesterov vs Polyak	$\kappa=1000$: Nest 237、HB 256 步
12	Muon 谱范数 vs Frobenius	谱范数 Muon 0.037、Frob Muon 63266
25	HB $\equiv$ Chebyshev 定常极限	末段 max gap = 1.7×10^{-13}
26	Adam 2-极限环	$x^\pm=(0.025, -0.025)$
27	五次多项式 NS vs 标准 NS	5 步达 10^{-16}
28	Muon 谱范数 trust-region	Muon 0.028~0.037 一致
29	NAG-ODE vs 离散 NAG/HB	NAG 与 AVD-ODE 相近
30	NS 收敛盆 $\sqrt{3}$	11 个 $\sigma_0 > \sqrt{3}$ 全发散

6.2 重要图的解读

图 1 (exp1) $\kappa \in \{10, 100, 1000\}$ 的三栏对照。Momentum 在所有 κ 上显著快于 GD; $\kappa = 1000$ 时 Adam 1133 步收敛, GD 在 MAX_ITER=2000 内未达 10^{-6} 。




图 4: $\kappa \in \{10, 100, 1000\}$ 下 GD / Heavy-ball / Adam 收敛曲线（实验 1）

图 25 (exp25, 主结果) 在 $\kappa = 100, 200$ 步的设置下, Heavy-ball 与 Chebyshev 半迭代的定常极限关系得到验证: 左图两者末段 $f - f^*$ 曲线几乎完全重合, 末 50 步最大差距为 1.7×10^{-13} 。




图 5: Heavy-ball 与 Chebyshev 半迭代的定常极限关系 (实验 25)

图 26 (exp26, Adam 2-极限环) 四组超参对照中, 第 2 组形成清晰的 2-极限环 $\{0.025, -0.025\}$, 是 Bock & Weiß (2022) 理论的直接数值复现。




图 6: Adam 2-极限环的数值复现 (实验 26)

图 28 (exp28, Muon 的主场) 在谱范数 trust-region 损失 $\frac{1}{2}\|W - W^*\|_\sigma^2$ 上, 5 个种子的 Muon 均单调下降到 0.028 ~ 0.037 的稳定带, 表明其正交化方向与谱范数几何相匹配。




图 7: Muon 在谱范数 trust-region 损失上的表现 (实验 28)

读图说明 (为何 GD 曲线更低、更快?) 初值统一取 $W_0 = 0$ 时, Frobenius 梯度 $\nabla f(0) = 0 - W^* = -W^*$, GD 沿 W^* 方向直线推进, 对本实验随机生成的 W^* 往往可将谱范数损失压至 10^{-32} 量级 (exp28 五种子的 GD 终值均 $\sim 10^{-32}$)。这是**初值与梯度形式的巧合**, 并不表示 Muon 的全局最优性弱于 GD。

Muon 每步对 $g_k = W_k - W^*$ 做 Newton-Schulz 正交化, 得到的是定理 4.2 中**谱范数 trust-region 线性子问题**的最速下降方向, 而非全局最小化 $\frac{1}{2}\|W - W^*\|_F^2$ 的精确最速下降; 因此 Muon 会稳定停在约 0.03 的平台, 而不会像 GD 那样在 $W_0 = 0$ 时直达机器精度。本图要验证的是: Muon 在谱范数几何下**跨种子稳定下降** (与 exp12 右图 Frobenius 二次上 Muon 发散形成对照), 而非与 GD 比拼最终精度。

7 结论

1. **统一模板** $x_{k+1} = x_k - P_k g_k$ 把 GD (Richardson)、Heavy-ball (谱加速)、Adam (动态 Jacobi)、Sophia (对角 Hessian)、Muon (极分解) 放在同一数值迭代框架下。
2. **谱半径分析**精确预测二次问题上的收敛率: GD $\rho^* = (\kappa - 1)/(\kappa + 1)$ 、Polyak HB $\rho^* = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$; 实验 2 直接验证。
3. **HB 是 Chebyshev 半迭代的定常极限** (定理 3.3 + 实验 25): 两者末段 gap 差距 1.7×10^{-13} 。
4. **Newton-Schulz 二次收敛**有干净的递推 (4.2), 收敛盆 $(0, \sqrt{3})$ 由实验 30 在 100 个初值上直接观察证实。
5. **Muon 的真本质**是谱范数 trust-region 线性子问题的最速下降方向 (定理 4.2): 它与 GD 优化不同的**每步子问题**, 不宜在同一 Frobenius/谱范数损失上简单比优劣 (详见 §4.5)。实验表明: Frobenius 二次上 Muon 与 GD 几何错配 (exp12 右); 谱范数恢复上 Muon 跨种子稳定下降 (exp28), 而 GD 在 $W_0 = 0$ 时因初值巧合更快。
6. **Adam 2-极限环** (实验 26) 复现 Bock & Weiß (2022): 即使最简凸 $f(x) = x^2/2$ 上 Adam 也可能不收敛。

7. **NAG** $\leftrightarrow$ **ODE** (实验 29): AVD-ODE 的 RK4 解与离散 NAG 在 $t = \sqrt{\eta}k$ 下呈现相近轨迹。

8 作者分工与贡献

本报告由两人合作完成，具体分工如下：

表 4: 作者分工与贡献比例

作者	学号	主要贡献
赵泽霖	2023010848	理论推导、定理证明、Newton-Schulz/Muon 章节撰写、报告整体架构
史云天	2023010836	数值实验设计与实现、代码开发、图表生成、实验章节撰写

贡献比例：赵泽霖 50%，史云天 50%。

参考文献

- [1] Anonymous. Accelerating newton-schulz via chebyshev polynomials. *arXiv:2506.10935*, 2025.
- [2] Sebastian Bock and Michael Weiß. Non-convergence and limit cycles in the adam optimizer. *arXiv:2210.02070*, 2022.
- [3] Ernst Hairer, Syvert P. Nørsett, and Gerhard Wanner. *Solving Ordinary Differential Equations I*. Springer, 1993.
- [4] Nicholas J. Higham. *Functions of Matrices: Theory and Computation*. SIAM, 2008.
- [5] Keller Jordan et al. Muon: An optimizer for hidden layers in neural networks. GitHub, 2024.
- [6] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *ICLR*, 2015.
- [7] Dmitry Kovalev. Understanding gradient orthogonalization for deep learning via non-euclidean trust-region optimization. *arXiv:2503.12645*, 2025.
- [8] Jiawei Liu et al. Muon is scalable for LLM training. *arXiv:2502.16982*, 2025.
- [9] B. T. Polyak. Some methods of speeding up the convergence of iteration methods. *USSR Computational Mathematics and Mathematical Physics*, 1964.
- [10] Youssef Saad. *Iterative Methods for Sparse Linear Systems*. SIAM, 2 edition, 2003.
- [11] G. Schulz. Iterative berechnung der reziproken matrix. *ZAMM*, 13:57–59, 1933.
- [12] Bin Shi, Simon S. Du, Michael I. Jordan, and Weijie J. Su. Understanding the acceleration phenomenon via high-resolution differential equations. *Mathematical Programming*, 2021.
- [13] Weijie Su, Stephen Boyd, and Emmanuel J. Candès. A differential equation for modeling nesterov’s accelerated gradient method. *Journal of Machine Learning Research*, 17:1–43, 2016.
- [14] Lloyd N. Trefethen and David Bau. *Numerical Linear Algebra*. SIAM, 1997.

A 实验数值摘要 (精选)

数据来源: `data/experiment_results.json`。完整版见 `report/appendix_auto.md`。

A.1 实验 1: 达到 10^{-6} 的迭代步数

下表给出不同条件数下各方法达到 10^{-6} 精度所需的迭代步数。

κ	GD	Polyak HB	Adam
10	39	17	162
100	439	68	288
1000	— (>2000)	256	1133

A.2 实验 12: Muon 在两种损失上

Muon 在谱范数损失与 Frobenius 矩阵二次上的最终损失对比如下。

目标	Muon-NS 最终	GD 最终	Adam 最终
谱范数损失 (80 步)	0.037	2.4×10^{-32}	1.1×10^{-4}
Frobenius 二次 (400 步)	63266	51.4	—

A.3 实验 25: HB $\equiv$ Chebyshev 半迭代

Heavy-ball 与 Chebyshev 半迭代末段数值对比如下。

量	值
200 步后 $f - f^*$ (HB)	10^{-30}
200 步后 $f - f^*$ (Cheb)	10^{-30}
max gap diff (末 50 步)	1.7×10^{-13}

A.4 实验 30: Newton-Schulz 收敛盆

理论收敛盆上界 $\sqrt{3} \approx 1.7321$ 。在 100 个 $\sigma_0 \in [0.05, 2.5]$ 中, **11 个发散**, 且全部满足 $\sigma_0 > \sqrt{3}$, 与定理 4.1 的预言完全一致。

B 完整证明

B.1 定理 3.1 的证明 (GD 线性收敛)

设 $A = Q\Lambda Q^\top$, $0 < \mu \leq \lambda_i \leq L$ 。GD 更新 $x_{k+1} = x_k - \eta(Ax_k - b)$, 误差 $e_k = x_k - x^*$ 满足 $e_{k+1} = (I - \eta A)e_k$ 。在特征基下各模态衰减为 $|1 - \eta\lambda_i|$, 故

$$\|e_{k+1}\|_2 \leq \max_i |1 - \eta\lambda_i| \cdot \|e_k\|_2 = \rho(\eta) \|e_k\|_2.$$

$\rho(\eta) = \max\{|1 - \eta\mu|, |1 - \eta L|\}$ 在 $\eta = 2/(\mu + L)$ 处取最小值 $\rho^* = (\kappa - 1)/(\kappa + 1)$ 。□

B.2 定理 3.2 的证明 (Polyak 最优 Heavy-ball)

在特征基下, Heavy-ball 对每个模态 λ 给出 2×2 矩阵 $T(\lambda)$, 特征方程 $z^2 - (1 - \eta\lambda + \beta)z + \beta = 0$ 。最优情形要求所有 $\lambda \in [\mu, L]$ 满足 $(1 - \eta\lambda + \beta)^2 \leq 4\beta$, 端点同时取等:

$$1 - \eta\mu + \beta = 2\sqrt{\beta}, \quad -(1 - \eta L + \beta) = 2\sqrt{\beta}.$$

解得 $\beta^* = \left(\frac{\sqrt{L}-\sqrt{\mu}}{\sqrt{L}+\sqrt{\mu}}\right)^2$, $\rho^* = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$, $\eta^* = 4/(\sqrt{L} + \sqrt{\mu})^2$ 。□

B.3 定理 3.3 的证明 (HB 是 Chebyshev 半迭代的定常极限)

Chebyshev 半迭代 (Hageman-Young 形式):

$$\omega_1 = \frac{1}{1 - \sigma^2/2}, \quad \omega_{k+1} = \frac{1}{1 - \sigma^2\omega_k/4}, \quad x_{k+1} = \omega_{k+1} \left(\frac{r_k}{d} + x_k - x_{k-1} \right) + x_{k-1},$$

其中 $d = (L + \mu)/2$, $\sigma = (L - \mu)/(L + \mu)$ 。令 $\omega_k \rightarrow \omega_\infty$, 不动点方程给出 $\omega_\infty = 2/(1 + \sqrt{1 - \sigma^2})$ 。可验证 $\eta_\infty = \omega_\infty/d = \eta^*$, $\beta_\infty = \omega_\infty - 1 = \beta^*$, 故 Chebyshev 在系数收敛后退化为 Polyak 最优 Heavy-ball。实验 25 末段 gap 1.7×10^{-13} 与该解释一致。□

B.4 命题 3.4 的证明

$\beta_1 = 0$ 时 $\hat{m}_k = g_k$; v_k 趋于 $\mathbb{E}[g \odot g]$ 。对二次问题 $g(x) = A(x - x^*)$, 当 A 对角且 $\Sigma \propto I$ 时 $\mathbb{E}[g \odot g] \propto \text{diag}(A)^2$, 故 $P_k \approx \eta \text{diag}(A)^{-1}$, 恰为 Jacobi 预条件器。□

B.5 定理 4.1、定理 4.2 的证明

定理 4.1 的完整证明见正文 §4; 定理 4.2 的证明见正文, 基于 von Neumann 迹不等式取等条件。